Predicción de mora en tarjetas de crédito

Cómo asignar la cobranza preventiva donde evita más pérdida

Informe final — Proyecto Final Integrador (Unidad N°9)

Diplomado en Ciencia de Datos y Análisis Avanzado

Equipo: GRUPO 19

Integrantes

Agustin Alejandro Martinez

Facundo Martin Rojas

Ana Paula Athor

Alexia Antonoglou

Esteban German Rojas Serrano

Fecha: octubre de 2026

Índice

1. Resumen ejecutivo
2. Definición del problema y relevancia
3. Datos y metodología
4. Modelado y evaluación
5. Interpretación del modelo
6. Impacto en el negocio
7. Conclusiones y recomendaciones
Anexos A. Diccionario de variables · B. Decisiones de limpieza · C. Comparación de algoritmos y calibración · D. Trazabilidad con la consigna y la pre-entrega · E. Código y reproducibilidad

1. Resumen ejecutivo

Problema. Un emisor de tarjetas puede contactar cada mes, antes del vencimiento, sólo al 20% de su cartera: es lo que alcanza su equipo de cobranza preventiva. Hoy decide a quién llamar con reglas simples (primero los más atrasados, o los de mayor saldo) que no estiman cuánto se puede perder con cada cliente. **Público:** interno; cobranzas usa el ranking y riesgo de crédito es dueño del modelo.

Solución. Un modelo de gradient boosting estima la probabilidad de que cada cliente incumpla el mes siguiente. Multiplicada por su saldo, da la **pérdida esperada** del cliente; la gestión se asigna a quienes la tienen más alta, con la misma capacidad que hoy.

Resultados clave, medidos sobre 6.002 clientes que el modelo nunca vio:

- Con 1.200 gestiones, el modelo concentra **NT$ 51,5 millones** de deuda en riesgo de los clientes que efectivamente incumplen, contra NT$ 43,7 millones de la mejor regla (mayor saldo) y NT$ 34,5 millones de la regla vigente. Es **17,7% más** que la mejor regla (intervalo de confianza del 95%: 12,4% a 23,6%).
- La ventaja se repite en las cinco particiones de datos probadas (entre 17,7% y 23,0%) y se mantiene en los 27 escenarios de supuestos económicos evaluados.
- Con supuestos conservadores de pérdida y de efectividad de la gestión, el **beneficio neto es NT$ 5,9 millones por mes**, contra NT$ 5,0 millones de la mejor regla y NT$ 3,9 millones de la regla vigente, con el mismo costo de campaña.
- Cumple **cinco de los seis umbrales de éxito** fijados antes de modelar. El que no cumple: detectar 10 puntos más de morosos que la regla vigente (detecta 2,3 puntos más).

Impacto esperado. Para planificar conviene la media entre particiones: unos **NT$ 8,2 millones más por mes de exposición en mora gestionada** por cada 6.000 clientes de cartera, respecto de la mejor regla disponible. El costo de implementarlo es bajo: el modelo se entrena en segundos con datos que el emisor ya tiene.

Recomendación. Adoptarlo a través de una **prueba piloto con grupo testigo**: los datos muestran a quién conviene llamar, pero no cuánta mora evita realmente una llamada. Esa cifra sólo la puede dar un experimento controlado.

2. Definición del problema y relevancia

Contexto. En una cartera de tarjetas, cada cliente que entra en mora genera una pérdida que, una vez producida, cuesta mucho más recuperar que prevenir. La cobranza preventiva (contactar al cliente antes del vencimiento para ofrecerle un plan o recordarle el pago) es más barata y más efectiva, pero tiene un límite: el equipo puede gestionar sólo una fracción de la cartera por mes. La pregunta de negocio, entonces, no es sólo quién va a incumplir, sino **a quién contactar primero con un presupuesto fijo**.

Motivación. Las dos reglas que hoy se usan tiran en direcciones opuestas. Priorizar a los más atrasados (regla vigente) encuentra muchos morosos, pero de saldos chicos. Priorizar a los de mayor saldo encuentra deudas grandes, pero menos morosos que si se eligiera al azar. Un modelo puede combinar las dos cosas: riesgo y monto.

Objetivo medible. Maximizar la exposición en mora capturada dentro del 20% de la cartera gestionable (1.200 de cada 6.000 clientes) y superar a la mejor regla en al menos un 10%.

KPI primario: exposición en mora capturada a capacidad fija (NT$/mes). Es la suma del saldo de los clientes gestionados que efectivamente incumplen. No depende de ningún supuesto: el negocio lo calcula con la lista de gestionados, quién incumplió y su saldo. **KPI derivado: beneficio neto** = exposición capturada × severidad de la pérdida (60%) × efectividad de la gestión (20%) − 200 NT$ por contacto. Esos tres parámetros son supuestos que se deben acordar con el negocio.

Tabla 1. Hipótesis de trabajo y veredicto con el modelo final

	Hipótesis	Evidencia	Veredicto
H1	El historial de pago predice más que los datos demográficos	PR-AUC 0,487 contra 0,254; quitarlo cuesta 0,110	Se sostiene
H2	El modelo detecta más morosos que la regla vigente, a igual capacidad	+2,3 pp (IC95: 1,0 a 4,0)	Se sostiene, lejos de la meta de 10 pp
H3	Variables derivadas (utilización, ratio de pago) agregan señal	+0,002 de PR-AUC (umbral: 0,01)	Refutada
H4	Excluir los datos demográficos no degrada el modelo	Costo: 0,001 de PR-AUC	Se sostiene

Restricciones. Los datos son de un emisor de Taiwán (2005), una sola foto de la cartera, sin ingresos, sin datos de buró y sin registro de gestiones de cobranza. La capacidad del equipo es fija (20%). Los atributos protegidos (sexo, edad, estado civil) y sus sustitutos están sujetos a restricciones regulatorias en el otorgamiento y la gestión del crédito.

Importancia estratégica. La mora es el principal costo variable de una cartera de tarjetas. Mejorar la asignación de un recurso que ya existe (el equipo de cobranzas) no requiere más presupuesto: es una mejora de eficiencia sobre un gasto fijo, medible desde el primer mes.

3. Datos y metodología

3.1 Fuente y características

Se usó Default of Credit Card Clients (UCI Machine Learning Repository, dataset 350; Yeh y Lien, 2009), con licencia CC BY 4.0. Tiene **30.000 clientes y 25 columnas**: límite de crédito, cuatro datos demográficos y, para cada uno de los seis meses de abril a septiembre de 2005, el estado de pago, el saldo del resumen y el monto pagado. La variable a predecir es si el cliente incumple el mes siguiente: lo hace el **22,1%** (6.636 clientes). Cada afirmación de la documentación (filas, columnas, ausencia de nulos) se verificó contra el archivo.

Tabla 2. Problemas de calidad detectados y decisión tomada

Problema	Magnitud	Decisión
Valores faltantes	0	No requiere imputación
Códigos fuera del diccionario en educación y estado civil	399 registros (1,3%)	Educación: agrupados en «otros» (no difieren); estado civil 0: se conserva aparte
Códigos de estado de pago no documentados (−2, 0)	66,9% de las celdas	Se interpretan como «sin atraso» y se mantienen ordinales
Saldos negativos	1.930 clientes (6,4%)	Se conservan: son saldo a favor
Montos con cola larga	8% a 10% atípicos por variable	No se transforman (el modelo de árboles no lo necesita)
Filas duplicadas idénticas (salvo el ID)	35 pares	Se conservan, pero cada par queda del mismo lado de la partición

3.2 Conclusiones del análisis exploratorio

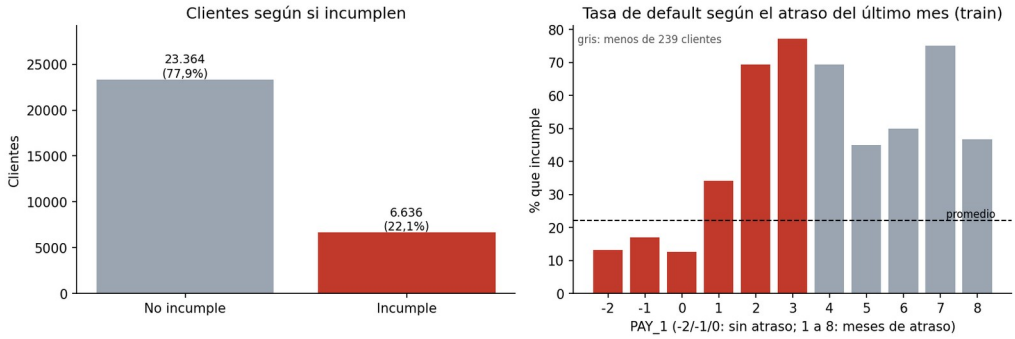


Figura 1. Desbalance de clases y tasa de incumplimiento según el atraso del último mes. En gris, códigos con menos de 239 clientes.

- **El atraso reciente es la señal dominante.** Sin atraso, incumple entre el 13% y el 17%; con un mes de atraso, el 34%; con dos o tres meses, entre el 69% y el 77%. Las seis variables de estado de pago encabezan el ranking de información mutua.
- **Los datos demográficos casi no informan.** Por sí solos apenas superan al azar (PR-AUC de 0,254 contra 0,221), frente a 0,487 del historial de pago (H1). Esto permitió dejarlos fuera del modelo a muy bajo costo.

- **La exactitud (accuracy) no sirve como métrica.** Predecir que nadie incumple acierta el 77,9% de las veces y no detecta ni un moroso. Por eso se usa PR-AUC, que mide cuántos morosos hay entre los priorizados.
- **Los montos tienen colas largas y relaciones no lineales con el riesgo**, lo que anticipaba que un modelo de árboles le ganaría a uno lineal.

3.3 Preparación de los datos

Toda decisión que mira el resultado (agrupar categorías, elegir variables) se tomó **sólo con los datos de entrenamiento**, para no contaminar la evaluación. Se renombró PAY_0 a PAY_1 tras verificar el orden temporal de las columnas. Se excluyeron el identificador y los cuatro datos demográficos (sexo, edad, educación, estado civil); el costo de excluirlos se midió y es despreciable (H4). La partición agrupa los duplicados, para que ninguno quede repartido entre entrenamiento y prueba. El detalle de las diez decisiones de limpieza está en el Anexo B.

3.4 Metodología: CRISP-DM y esquema de validación

Tabla 3. Fases de CRISP-DM y su aplicación en el proyecto

Fase	Qué se hizo
Comprensión del negocio	KPI en NT$, umbrales de éxito y reglas de negocio de referencia, fijados antes de modelar
Comprensión de los datos	Verificación de la fuente, auditoría de calidad, análisis exploratorio
Preparación de los datos	Partición sin fuga de duplicados; limpieza decidida sólo con entrenamiento
Modelado	Baseline logístico, comparación de tres algoritmos, selección con criterio declarado
Evaluación	Holdout usado una sola vez, estabilidad, sensibilidad a supuestos, equidad
Despliegue	Fuera de alcance; se propone un piloto con grupo testigo (sección 7)

Se apartó un **20% de los clientes (6.002) como conjunto de prueba**, que no se tocó hasta el final. Con el 80% restante, una **validación cruzada de cinco pliegues** decidió todo: el algoritmo, la forma de ordenar a los clientes, la mejor regla de referencia y si calibrar las probabilidades. El conjunto de prueba se usó **una sola vez**, para medir. Para estimar la incertidumbre se usaron 5.000 remuestreos (bootstrap) y cinco particiones distintas de los datos. **Limitación:** los datos son una sola foto de la cartera, por lo que no fue posible validar con meses posteriores, como correspondería en producción.

4. Modelado y evaluación

4.1 Algoritmos probados y criterio de selección

Se compararon tres algoritmos con las mismas variables, los mismos pliegues y sin búsqueda de hiperparámetros: la **regresión logística** (baseline lineal e interpretable), el **gradient boosting** (árboles en secuencia, que capturan interacciones como atraso × saldo) y el **Random Forest** (árboles en paralelo). El criterio se fijó antes de correr: **gana el que más exposición en mora captura**, y si uno más barato de entrenar queda a menos del 1% del mejor, gana el más barato.

Tabla 4. Comparación de algoritmos (validación cruzada sobre entrenamiento)

Algoritmo	PR-AUC (media ± desvío)	ROC-AUC	Exposición capturada (M NT$)	Tiempo de CV
Regresión logística	0,503 ± 0,015	0,723	181,5	0,4 s
Gradient boosting (elegido)	**0,558 ± 0,019**	**0,780**	**195,0**	**1,2 s**
Random Forest	0,558 ± 0,019	0,783	196,1	53 s

Los dos modelos de árboles superan claramente a la logística (+0,055 de PR-AUC; +7,4% de exposición) y son prácticamente equivalentes entre sí. El Random Forest captura un 0,6% más, dentro de la tolerancia, pero tarda más de 40 veces más en entrenar: **se eligió gradient boosting**. En el conjunto de prueba, el elegido volvió a ser el que más exposición captura (Anexo C).

4.2 Cómo se usa el modelo: probabilidad o pérdida esperada

El modelo puede ordenar a los clientes de dos formas: por **probabilidad de incumplir** (encuentra más morosos) o por **pérdida esperada**, probabilidad × saldo (encuentra más deuda en riesgo). Se eligió la segunda, porque es la que mueve el KPI: sobre entrenamiento capturó NT$ 196,5 millones contra 137,1 millones de la primera. Como la pérdida esperada multiplica la probabilidad por pesos, esa probabilidad tiene que ser realista: se aplicó una **calibración isotónica**. En el conjunto de prueba, la diferencia entre la probabilidad predicha y la tasa observada es de 0,8 puntos en promedio por decil (Anexo C).

4.3 Resultados en el conjunto de prueba

Tabla 5. Métricas del modelo final sobre 6.002 clientes no vistos

Métrica	Valor	Lectura
PR-AUC (métrica primaria)	0,547 (IC95: 0,518 a 0,576)	2,5 veces el azar (0,221)
ROC-AUC	0,773 (IC95: 0,758 a 0,788)	Comparable con la literatura del dataset
Brier score	0,136	21% mejor que predecir el promedio
Recall / precisión al 20%*	50,0% / 55,3%	Detecta la mitad de los morosos gestionando un quinto de la cartera

Métrica	Valor	Lectura
F1 al 20%*	0,526	Se reporta; no decide (pesa igual un moroso no detectado que un contacto de más)
Lift al 20%*	2,50	Concentra 2,5 veces más mora que el azar

* Ordenando por probabilidad. Al ordenar por pérdida esperada, el recall baja a 36,6% a cambio de capturar más deuda (sección 6).

Tabla 6. Umbrales de éxito, fijados antes de modelar

	Umbral	Resultado	¿Cumple?
U0	Exposición capturada ≥ 10% sobre la mejor regla	+17,7%	Sí
U1	Recall ≥ 10 puntos sobre la regla vigente	+2,3 pp	**No**
U2	PR-AUC en validación cruzada ≥ 0,55	0,558	Sí
U3	Lift al 20% ≥ 2,0	2,50	Sí
U4	Beneficio neto positivo y mayor que el de la mejor regla	5,94 contra 5,01 M NT$	Sí
U5	Excluir los datos demográficos cuesta < 0,01 de PR-AUC	0,001	Sí

El baseline logístico no alcanzaba U2 (0,503); el modelo final sí. U1 no se cumple y se informa así: la regla vigente ya es buena para encontrar morosos, y la mejora del modelo está en el dinero, no en la cantidad de casos.

5. Interpretación del modelo

Se usaron cuatro herramientas: **permutación** (desordenar un bloque de variables y medir cuánto empeora el modelo), **ablación** (reentrenar sin ese bloque), **dependencia parcial** (mover una sola variable y ver cómo cambia la probabilidad) y **SHAP**, que reparte cada predicción entre las variables. Describen cómo razona el modelo; no demuestran causalidad.

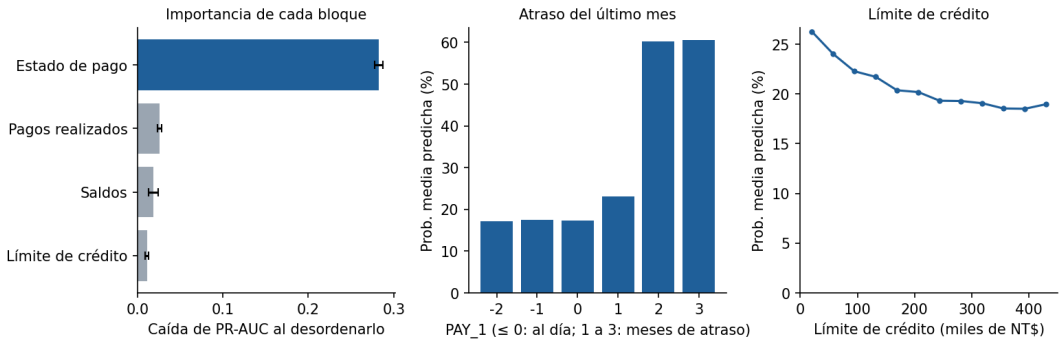


Figura 2. Importancia de cada bloque de variables (izquierda) y efecto del atraso del último mes y del límite de crédito sobre la probabilidad predicha.

Tabla 7. Importancia de cada bloque de variables, medida de tres formas

Bloque	Caída de PR-AUC al desordenarlo	Caída de la exposición capturada	Cambio de PR-AUC al quitarlo y reentrenar	Aporte SHAP medio (log-odds)
Estado de pago (6 meses)	0,283	16,6%	−0,110	0,647
Pagos realizados (6 meses)	0,026	0,4%	−0,004	0,308
Saldos facturados (6 meses)	0,018	6,5%	−0,006	0,188
Límite de crédito	0,011	1,4%	−0,005	0,176

- **El estado de pago es casi todo el modelo.** Las tres mediciones coinciden. Desordenarlo baja la PR-AUC de 0,547 a 0,264, quitarlo y reentrenar cuesta 0,110 y ningún otro bloque lo reemplaza. Es la prueba directa de H1. Solo el atraso del último mes (PAY_1) aporta casi el triple que la segunda variable, el límite de crédito.
- **Pagos, saldos y límite aportan poco cada uno y se reemplazan entre sí:** quitar cualquiera cuesta menos de 0,01. SHAP y la permutación coinciden en el orden: los pagos realizados son el segundo bloque.
- **Dirección del efecto.** Con un mes de atraso, la probabilidad media pasa del 17% al 23%; con dos o más meses, al 60%. SHAP confirma la dirección: más atraso sube el riesgo, y pagos más altos y un límite mayor lo bajan (correlación entre el valor y su aporte de −0,92 para el límite y el último pago). Como el límite lo asigna el propio banco, refleja su evaluación previa del cliente y puede arrastrar sesgos históricos; por eso se auditó la equidad (sección 6.5).

Caso local. El cliente 27499 del conjunto de prueba estuvo sin atraso de abril a agosto y registró dos meses de atraso en septiembre, con un saldo de NT$ 613.860. SHAP parte del valor promedio del modelo (17,6% de probabilidad) y muestra que **el atraso de septiembre explica casi todo el aumento** (+2,47 en log-odds). El pago de NT$ 37.300 de ese mes lo compensa en parte (−0,22) y el saldo alto suma poco (+0,21). Resultado: 74% de probabilidad (calibrada) y una pérdida esperada de NT$ 455.713, la más alta entre los morosos seleccionados. Con septiembre al día bajaría al 15%. Efectivamente incumplió.

6. Impacto en el negocio

6.1 El modelo contra las reglas actuales

Las cinco estrategias gestionan 1.200 clientes, el 20% del conjunto de prueba: mismo presupuesto, distinto criterio para elegir a quién llamar.

Tabla 8. Estrategias de priorización a igual capacidad (conjunto de prueba, por mes)

Estrategia	Morosos alcanzados	Recall	Exposición capturada (NT$)	Beneficio neto (NT$)
Azar	282	21,3%	13.384.038	1.366.085
Regla vigente: más atrasados	633	47,7%	34.509.973	3.901.197
Mejor regla: mayor saldo	243	18,3%	43.740.502	5.008.860
Modelo, por probabilidad	664	50,0%	32.972.552	3.716.706
Modelo, por pérdida esperada (recomendado)	**485**	**36,6%**	**51.471.700**	**5.936.604**

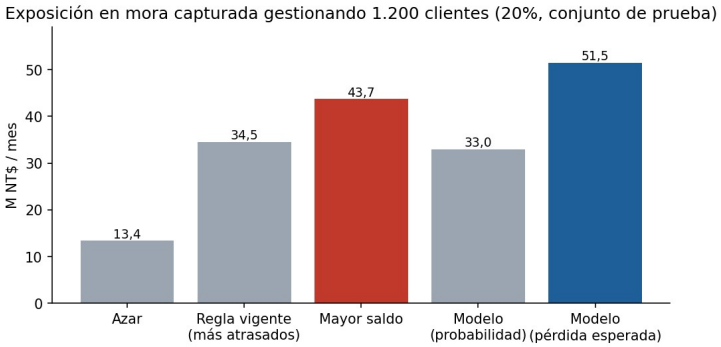


Figura 3. Exposición en mora capturada por estrategia, en millones de NT$ por mes.

El modelo recomendado captura **NT$ 7,7 millones más que la mejor regla y NT$ 17,0 millones más que la regla vigente**, por mes y con el mismo equipo. Lo logra eligiendo menos morosos que la regla vigente (485 contra 633), pero de deudas más grandes: es un cambio de criterio que el negocio tiene que aceptar de manera explícita (ver riesgos).

6.2 Cuán firme es la ventaja

- **Remuestreo (5.000 veces):** la ventaja sobre la mejor regla va de 12,4% a 23,6%; nunca fue negativa y supera el 10% en el 99,9% de los casos.
- **Cinco particiones distintas de los datos:** la ventaja va de 17,7% a 23,0% (media 19,8%; NT$ 8,2 millones por mes).
- **27 escenarios de supuestos** (severidad 40% a 80%, efectividad 10% a 30%, capacidad 10% a 30%): el modelo gana en todos.

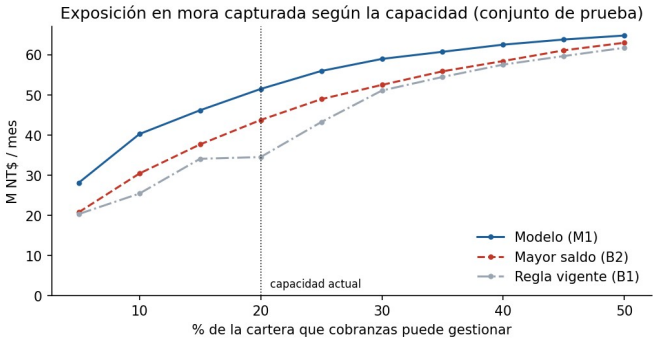


Figura 4. Exposición capturada según la capacidad del equipo. La ventaja es mayor cuanto más escasa es la capacidad.

6.3 Beneficios, automatización y escalabilidad

El beneficio es de eficiencia: el mismo equipo y el mismo costo de campaña de OPEX directo (NT$ 240.000 por mes cada 6.000 clientes, a razón de NT$ 200 por contacto) se dirigen a una deuda en riesgo mayor, unos **NT$ 1,4 millones más de exposición gestionada por mes por cada 1.000 clientes**. El beneficio neto del modelo supera al de la mejor regla en NT$ 0,93 millones por mes y al de la regla vigente en NT$ 2,0 millones, unos **NT$ 11 y 24 millones por año** cada 6.000 clientes.

En términos de estructura financiera, el CAPEX (inversión inicial de puesta en marcha) se estima en ~NT$ 500.000 para la integración técnica y la prueba piloto; es sumamente bajo porque no requiere licencias propietarias ni hardware especial, utilizando datos que el emisor ya posee. El OPEX recurrente se estima en unos NT$ 50.000 mensuales de infraestructura en la nube y mantenimiento MLOps, adicionales al costo de campaña. Con un beneficio neto incremental de NT$ 0,93 millones mensuales respecto a la mejor regla, la inversión inicial (CAPEX) se recupera en el primer mes de operación (menos de 20 días). Estas cifras de inversión y mantenimiento son estimaciones del equipo y no surgen del modelo: hay que confirmarlas con el área de tecnología. El proceso se **automatiza** con un ranking mensual que reemplaza la selección manual; el modelo se entrena en segundos y escala sin cambios. Para producción hace falta reentrenarlo con datos propios y monitorear mensualmente su desempeño y calibración.

6.4 Riesgos y limitaciones

- **La efectividad de la gestión no está medida.** Los datos no registran ninguna gestión de cobranza: el 20% de efectividad es un supuesto. Es la crítica más importante al planteo y no se resuelve modelando, sino con un piloto con grupo testigo.
- **Prioriza saldo sobre cantidad de casos.** Alcanza a menos morosos que la regla vigente; si importa la mora temprana de saldos chicos, conviene reservarles capacidad.
- **Profecía autocumplida.** Una vez en uso, el modelo decide a quién se contacta, y esos contactos cambian el resultado que después se usa para reentrenarlo. **Mitigación:** reservar un 5-10% de la capacidad para clientes elegidos al azar, que además funcionan como grupo testigo del piloto.
- **Validez externa.** Datos de Taiwán de 2005, sin validación temporal: debe validarse con la cartera propia.

- **Supuestos económicos.** Severidad, efectividad y costo de contacto los tiene que confirmar el negocio: no cambian el orden de las estrategias, pero sí la magnitud del beneficio.

6.5 Consideraciones éticas y de privacidad

Privacidad. El dataset es público, está anonimizado (no contiene nombres, documentos ni datos de contacto) y su licencia permite este uso. En un uso real, los datos de los clientes quedarían alcanzados por la normativa de protección de datos personales (en Argentina, la Ley 25.326): uso limitado a la finalidad declarada, acceso restringido y resguardo.

Atributos protegidos. El modelo no usa sexo, edad, educación ni estado civil; excluirlos cuesta 0,001 de PR-AUC. Pero eso no garantiza un trato parejo, porque otras variables pueden funcionar como sustitutos (por ejemplo, el límite de crédito, que asignó el propio banco). Por eso se **auditó** el resultado por grupo, con esas variables usadas sólo para medir.

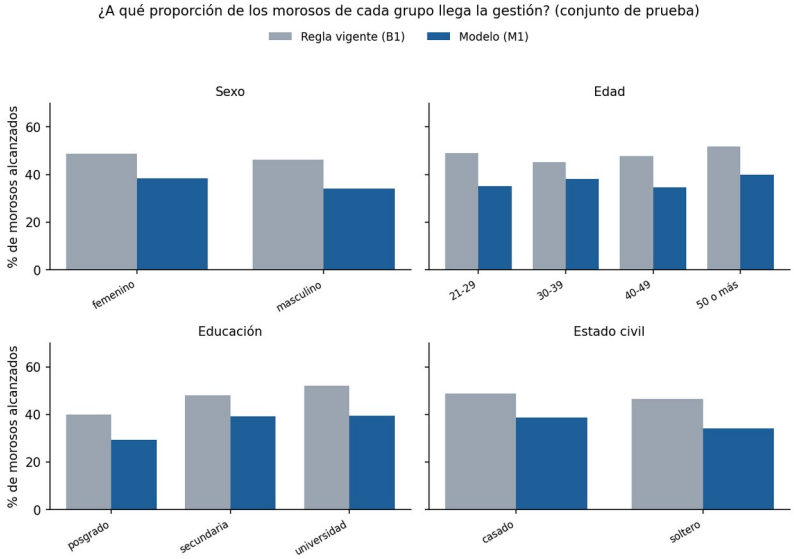


Figura 5. Proporción de los morosos de cada grupo que alcanza la gestión, en el conjunto de prueba.

En ningún atributo el modelo es distinguiblemente menos parejo que la regla vigente: las diferencias de brecha entre ambos (de −2,0 a +2,2 puntos) tienen intervalos de confianza que incluyen el cero. Las personas con posgrado reciben menos contactos (ratio de selección de 0,69 respecto del grupo más contactado), lo que es consistente con su menor tasa de mora (17,9% contra 24% a 26%). Todas las barras del modelo están por debajo de las de la regla vigente porque el modelo prioriza saldo y no cantidad de casos (6.1); eso afecta a todos los grupos por igual. **Mitigaciones:** revisión humana de los casos contactados, monitoreo mensual de estas brechas, un trato de cobranza no intrusivo y la posibilidad de que el cliente consulte por qué fue contactado.

7. Conclusiones y recomendaciones

Hallazgos principales.

- Un modelo de gradient boosting, ordenando a los clientes por pérdida esperada, captura entre un 12% y un 24% más de deuda en riesgo que la mejor regla disponible, con el mismo equipo. La ventaja es estable entre particiones y frente a los supuestos económicos.
- El historial de pago reciente explica casi todo el poder predictivo; los datos demográficos no aportan y quedaron fuera sin costo.
- La mejora está en el dinero, no en la cantidad de casos: el modelo no alcanza la meta de detectar 10 puntos más de morosos que la regla vigente.
- La auditoría no encontró que el modelo trate peor que la regla vigente a ningún grupo demográfico.
- Viabilidad financiera (CAPEX/OPEX, estimados por el equipo): La solución requiere un CAPEX inicial mínimo (~NT$ 500.000 para integración y prueba piloto) y un OPEX recurrente bajo (~NT$ 50.000/mes de MLOps en la nube, más NT$ 240.000/mes de campaña). El beneficio adicional de NT$ 0,93 millones/mes sobre la mejor regla paga la inversión inicial en el primer mes de operación.

Próximos pasos sugeridos.

1. **Piloto con grupo testigo** durante dos o tres meses: una parte de la capacidad se asigna con el modelo y otra con la regla vigente, para medir la mora efectivamente evitada.
2. **Acordar con el negocio** la severidad, la efectividad y el costo de contacto, y definir si se reserva capacidad para morosos de saldo bajo.
3. **Reentrenar con datos propios y recientes** y validar con meses posteriores (validación temporal).
4. **Ajustar los hiperparámetros** del modelo; en esta etapa se usó la configuración por defecto.
5. **Monitorear mensualmente** el desempeño, la calibración y las brechas por grupo.

Anexos

Anexo A. Diccionario de las diez variables principales

Tabla A1. Variables con mayor información mutua (sólo entrenamiento, media de 20 semillas)

Variable	Descripción	Rango observado	Información mutua
PAY_1	Estado de pago, septiembre 2005	−2 a 8	0,0774
PAY_2	Estado de pago, agosto 2005	−2 a 8	0,0496
PAY_3	Estado de pago, julio 2005	−2 a 8	0,0376
PAY_4	Estado de pago, junio 2005	−2 a 8	0,0326
PAY_5	Estado de pago, mayo 2005	−2 a 8	0,0296
PAY_6	Estado de pago, abril 2005	−2 a 8	0,0254
PAY_AMT1	Pago realizado, septiembre 2005	0 a 874 mil NT$	0,0231
PAY_AMT3	Pago realizado, julio 2005	0 a 896 mil NT$	0,0182
LIMIT_BAL	Límite de crédito otorgado	10 mil a 1 millón NT$	0,0163
AGE	Edad del titular (sólo para auditoría)	21 a 79 años	0,0028

Estado de pago: −2, −1 y 0 indican que no hay atraso; de 1 a 8, meses de atraso.

Anexo B. Decisiones de limpieza

Tabla B1. Decisiones tomadas (todas las que miran el resultado, sólo con entrenamiento)

	Decisión
L1	PAY_0 renombrada a PAY_1: restaura la secuencia de meses (orden verificado)
L2	Educación 0, 5 y 6 agrupados en «otros»: su tasa difiere 1,0 punto (intervalo de confianza que incluye el cero)
L3	Estado civil 0 conservado aparte: difiere 17,6 puntos de «otros»
L4	Identificador fuera del modelo
L5	Sexo, edad, educación y estado civil fuera del modelo: su aporte es menor que el umbral U5
L6	Estado de pago tratado como ordinal
L7	Saldos negativos conservados: son saldo a favor
L8	Sin imputación: no hay valores faltantes
L9	Duplicados exactos conservados: 35 pares con identificador propio
L10	La partición mantiene cada par duplicado del mismo lado (sin fuga entre entrenamiento y prueba)
P1-P3	Cola larga en montos, saldo a favor y codificación del estado de pago: resueltos por el algoritmo (los árboles son invariantes a transformaciones monótonas)
P5	Variables derivadas: evaluadas con el modelo final y descartadas (+0,002 de PR-AUC)
Abiertas	P4: posible sesgo histórico del límite de crédito. P6: saldo cero con pago positivo. P7: confirmar si 10 pares duplicados con montos no nulos son el mismo cliente

Anexo C. Comparación de algoritmos y calibración

Tabla C1. Los tres algoritmos en el conjunto de prueba (informativo: la elección se hizo antes, con entrenamiento)

Algoritmo	PR-AUC	ROC-AUC	Recall al 20%	F1 al 20%	Exposición (M NT$)
Regresión logística	0,500	0,715	47,3%	0,497	48,4
Gradient boosting (elegido)	**0,546**	**0,770**	**49,9%**	**0,524**	**52,6**
Random Forest	0,548	0,773	49,9%	0,524	52,0

Probabilidades sin calibrar en los tres, para compararlos en las mismas condiciones. El elegido también es el que más exposición captura en el conjunto de prueba.

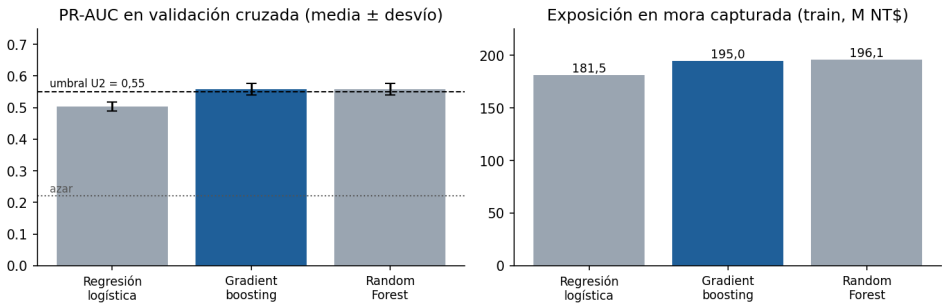


Figura C1. PR-AUC y exposición capturada por algoritmo en la validación cruzada. La línea punteada marca el azar (22%).

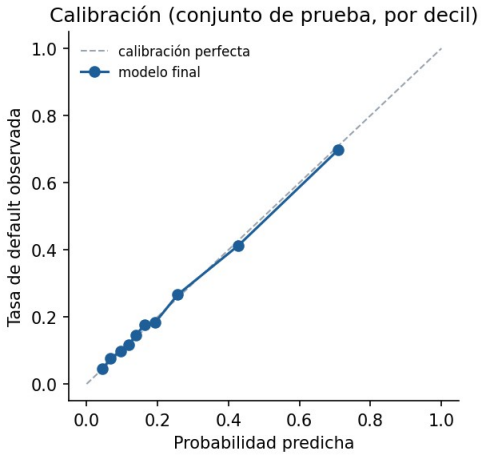


Figura C2. Calibración del modelo final en el conjunto de prueba: probabilidad predicha contra tasa observada, por decil.

Anexo D. Trazabilidad con la consigna, la pre-entrega y la devolución del tutor

Tabla D1. Criterios de evaluación de la consigna y dónde se cumplen

Peso	Criterio	Dónde se cumple en este informe
20%	Claridad del problema y alineación con el negocio	Secciones 1 y 2: objetivo medible fijado antes de modelar, KPI en NT$ sin supuestos, reglas de negocio como referencia, hipótesis y restricciones
20%	Rigor en la preparación de datos y la metodología	Sección 3: verificación de la fuente, problemas de calidad con cifras (Tabla 2), limpieza decidida sólo con entrenamiento, partición sin fuga de duplicados, CRISP-DM (Tabla 3); Anexo B
15%	Selección y defensa del modelo	Sección 4.1: tres algoritmos con las mismas variables y pliegues, regla de selección fijada antes de correr (Tabla 4); Anexo C
15%	Calidad de las métricas	Sección 4.3: PR-AUC contra el piso del azar, ROC-AUC, Brier, recall, precisión, F1 y lift al 20%, con intervalos de confianza; sección 6.2: estabilidad en cinco particiones
15%	Interpretación y cuantificación de valor	Sección 5: permutación, ablación, dependencia parcial, SHAP y un caso local; secciones 6.1 a 6.3: valor en NT$, sensibilidad a supuestos y escalabilidad
5%	Ética y privacidad	Sección 6.5: privacidad, costo medido de excluir atributos protegidos (U5) y auditoría de equidad con intervalos de confianza
10%	Impacto y claridad de la presentación	Resumen ejecutivo para directivos, figuras 3 a 5 y recomendación proporcional a la evidencia (piloto antes de adoptar)

Tabla D2. Observaciones del tutor y compromisos de la pre-entrega

Observación o compromiso	Estado	Evidencia
Tutor: duplicados sin fuga entre entrenamiento y prueba	Resuelto	La partición agrupa los duplicados: 0 pares partidos (sección 3.3; L10)
Tutor: las cinco estrategias, a igual capacidad	Resuelto	1.200 gestiones cada una (Tabla 8); la sensibilidad incluye la capacidad (6.2)
Tutor: el KPI en NT$ como primario	Resuelto	Es el KPI primario y el criterio para elegir el algoritmo (secciones 2 y 4.1)
Tutor: el impacto debe validarse con una prueba real o un grupo de control	Resuelto	El informe mide exposición gestionada, no mora evitada; la efectividad se declara supuesta y se recomienda un piloto con grupo testigo (6.4 y 7)
Probar modelos no lineales (H3 abierta)	Resuelto	Tres algoritmos; H3 vuelta a medir con el modelo final y refutada (Tabla 1)
P1-P3: outliers, saldo a favor y codificación del estado de pago	Resuelto	Los resuelve el algoritmo de árboles (Anexo B)
U1 y U2, abiertos con el baseline	U2 alcanzado; U1 no	PR-AUC 0,558 (meta 0,55); recall +2,3 pp contra la meta de 10 (Tabla 6)
Auditar la equidad	Resuelto	Selección y recall por grupo contra la regla vigente, con IC (sección 6.5)
Acordar los parámetros económicos con el negocio	Pendiente	Fuera del alcance del proyecto; recomendación 2 (sección 7)
P4, P6 y P7: sesgo del límite y registros a confirmar	Abierto	P4 cubierto en parte por la auditoría; P6 y P7 requieren confirmación del negocio (Anexo B)

Tabla D3. Baseline de la pre-entrega contra el modelo final

Indicador	Pre-entrega (logística)	Entrega final (gradient boosting)	Cambio
PR-AUC en validación cruzada	0,503	0,558	+0,055
PR-AUC en el conjunto de prueba	0,493	0,547	+0,054
ROC-AUC en el conjunto de prueba	0,719	0,773	+0,054
Lift al 20% (por probabilidad)	2,37	2,50	+0,13
Exposición capturada (M NT$ por mes)	50,5	51,5	+1,0
Ventaja media sobre la mejor regla (5 particiones)	17,0%	19,8%	+2,8 pp
Umbrales de éxito alcanzados	4 de 6	5 de 6	+1 (U2)

Anexo E. Código y reproducibilidad

Notebook baseline_v9.ipynb (Colab o local, semilla fija): cada resultado del modelo que cita este informe sale de resultados.json, que genera junto con las figuras. Versiones usadas: pandas 3.0.2, numpy 2.4.4 y scikit-learn 1.8.0 (con otras versiones las cifras cambian levemente). Repositorio con README: github.com/Frojas0/UTN-proyecto-final-integrador. SHA-256 de los datos: 30c6be3a bd8dcfd3 e6096c82 8bad8c2f 01123862 0f536922 0bd60cfc 82700933.